

Classificação de Sentimentos em Nível de Sentença: uma Abordagem de Múltiplas Camadas para *Tweets* em Língua Portuguesa

Silvia M. W. Moraes¹, André L. L. Santos¹, Matheus S. Redecker¹,
Rackel M. Machado¹, and Felipe R. Meneguzzi¹

¹Pontifícia Universidade Católica Rio Grande do Sul (PUCRS),
Avenida Ipiranga, 6681. Prédio 32, CEP 90619-900. Porto Alegre, RS-Brasil

{silvia.moraes, felipe.meneguzzi}@pucrs.br
andre.leonhardt.santos@gmail.com
{matheus.redecker, rackel.machado}@acad.pucrs.br

Abstract. *It is common practice among many customers to use social media for expressing their opinions on products and services. In this sense, the vast audience of social media has made of it a valuable source of information for companies. A method for obtaining such an information is through automatic extraction of opinions in text. Nevertheless, opinion extraction is a non-trivial task. In this paper, we use a multilayer architecture to assign polarity to tweets in Portuguese in the Technology and Sports domains. This study achieved encouraging results, which are superior to those achieved by means of a single layer architecture.*

Resumo. *É uma prática comum, entre muitos consumidores, usar as redes sociais para expressar suas opiniões a respeito de produtos e serviços. A popularidade crescente dessas redes as transformou em valiosas fontes de informação para organizações. Um modo de obter tais informações é por meio da extração automática de opiniões a partir de texto. Entretanto, essa extração de opinião não é uma tarefa trivial. Neste trabalho, usamos uma arquitetura de múltiplas camadas para definir a polaridade de tweets em português nos domínios Tecnologia e Esporte. Nosso estudo apresentou resultados encorajadores e superiores àqueles obtidos a partir de uma arquitetura de camada única.*

1. Introdução

As redes sociais são canais populares de comunicação e, por isso, são muito usadas para a expressão de opiniões sobre produtos e serviços. Neste ambiente virtual, tanto os clientes quanto as organizações podem encontrar informações de valor. Os clientes, por exemplo, podem usar essas informações para decidir por uma compra, e as organizações, para melhorar seus serviços, ambos baseando-se nos *feedbacks* postados pelos usuários dessas redes. No Brasil, em especial, o interesse pelas redes sociais é maior em relação a outros países. Segundo uma pesquisa realizada pela empresa comScore¹, em 2015, o tempo gasto pelos brasileiros em cada visita a uma rede social é 60% superior à média mundial [Banks 2015]. Mesmo sabendo que a maioria das postagens brasileiras são fotos e vídeos,

¹<http://www.comscore.com/>

muito texto em português circula por essas redes, principalmente pelo Twitter. Isso faz do português um idioma interessante para a pesquisa. O volume desses textos, no entanto, torna a análise manual extremamente custosa e, por vezes, proibitiva. Sendo assim, o caminho tem sido a busca por abordagens capazes de realizar tal extração automaticamente. A extração automática dessas opiniões, porém, é uma tarefa difícil, especialmente quando a fonte dessa informação são textos da *Web* [Kiritchenko et al. 2014]. A área que estuda essa tarefa é conhecida como Análise de Sentimentos ou Mineração de Opiniões [Liu 2010]. A Análise de Sentimentos se preocupa em determinar a natureza avaliativa de um texto, definindo se o mesmo expressa um sentimento positivo, negativo ou neutro [Kiritchenko et al. 2014]. Essa orientação de sentimentos é chamada de polaridade. A polaridade pode ser tratada basicamente em três níveis de granularidade: texto, sentença e entidade [Liu 2010]. No caso do texto, o objetivo é definir a polaridade do texto como um todo. Essa granularidade é mais indicada para *reviews* de um novo produto, por exemplo. No caso das entidades, a meta é identificar aspectos positivos e negativos de uma determinada entidade. Por exemplo, um usuário pode achar o processador (aspecto) de um notebook (entidade) maravilhoso, por ser rápido, mas detestar a bateria (aspecto) em razão da sua baixa durabilidade. Já em nível de sentença, que é o que tratamos em nosso trabalho, o objetivo é determinar a polaridade de uma frase, mais especificamente, no nosso caso, de um *tweet*.

Os resultados mais significativos para essa área de pesquisa foram obtidos para a língua inglesa. Como o inglês é uma língua universal, isso desperta maior interesse de pesquisa [Cambria et al. 2013] e, conseqüentemente, há mais ferramentas, *corpora*² e recursos linguísticos disponíveis para essa língua. Essa não é a realidade de outras línguas, como a portuguesa [Généreux and Martinez 2012, Prata et al. 2016, Moraes et al. 2015]. Enquanto a Wordnet³, que é uma grande base lexical para o inglês, tem mais de 15 anos, a Wordnet-BR [Silva 2010], definida para o português brasileiro, ainda está em construção. Há outras iniciativas, neste sentido, como a OpenWordNet-PT [de Paiva et al. 2012], para o português, que por ser mais recente, ainda não dispõe do mesmo volume e da mesma riqueza de relações da WordNet. Um outro problema refere-se à disponibilidade de *corpora* textuais anotados para o português [Moraes et al. 2015]. Há poucos, e os existentes geralmente não são muito volumosos. A escassez desse recurso dificulta o treinamento de algoritmos específicos para as diferentes tarefas referentes ao Processamento de Linguagem Natural (PLN), tais como *parsers* de dependência e normalizadores de texto, e também prejudica a comparação de resultados de pesquisa. Essa é uma das principais dificuldades de nossa pesquisa. Na maioria dos trabalhos estudados, os *corpora* usados foram construídos pelos próprios autores e, em geral, não estão disponíveis na *Web*. Dentre os trabalhos pesquisados, não encontramos nenhum que usasse o mesmo *corpus*, o que inviabiliza uma comparação direta entre as abordagens propostas. Os estudos tendem a ser pontuais, abordando apenas uma sub-tarefa da Análise de Sentimentos, sendo a classificação de polaridade a mais usual [Santos et al. 2015, Rosa et al. 2013, Morgado 2012, Souza and Vieira 2012, Filho et al. 2013]. É incomum, também, encontrarmos trabalhos que envolvam todas as etapas do processo e que usem uma arquitetura

²Corpora é o plural de corpus. Corpus é uma coleção de textos.

³WordNet agrupa substantivos, adjetivos, verbos e advérbios de acordo com o significado (synsets), provendo definições e relações de sinonímia, hiponímia, entre outras. Disponível em <https://wordnet.princeton.edu/>

de múltiplas camadas como a que utilizamos. O trabalho de Lambert and Rodriguez-Penago [Lambert and Rodriguez-Penagos 2014] é um dos poucos que utiliza uma arquitetura semelhante à nossa, contudo, utiliza *corpora* que não são formados por textos extraídos de redes sociais, mas por textos jornalísticos. Textos deste tipo exigem menos tratamento, uma vez que são mais formais, isto é, seguem convenções usuais de escrita, têm menor ocorrência de gírias, de abreviações e de erros gramaticais.

Neste artigo, descrevemos a arquitetura de múltiplas camadas que nós construímos para a classificação de sentimentos de *tweets* em português. Nossa arquitetura tem duas camadas: a primeira define a subjetividade das sentenças (*tweets*), e a segunda define a polaridade destas. O desempenho da extração de opinião melhora quando realizamos a classificação de subjetividade em uma etapa anterior, uma vez que esta descarta informações irrelevantes [Kamal 2013, Fersini et al. 2014]. Nós demonstramos, empiricamente, a eficácia da nossa abordagem usando dois *corpora* de domínios distintos: o domínio da Tecnologia, e o do Esporte. Além disso, analisamos a implementação da arquitetura de múltiplas camadas em contraste com a tradicional arquitetura de camada única para a classificação de polaridade de sentenças. Nossa análise experimental oferece dois resultados principais. Primeiro, a arquitetura de múltiplas camadas apresenta resultados compatíveis, e até superiores, ao estado da arte de trabalhos cujo foco é a língua portuguesa. Segundo, nós comparamos dois métodos diferentes para implementar as camadas e demonstramos que o método baseado em aprendizado de máquina é superior ao método baseado em léxico.

2. Arquitetura de Múltiplas Camadas para Classificação em Nível de Sentença

Nesta seção, nós detalhamos a arquitetura de múltiplas camadas para a classificação em nível de sentença. Descrevemos os *corpora* usados, seus pré-processamentos e os dois métodos de classificação estudados: baseado em léxico e em algoritmos de aprendizagem de máquina. A nossa abordagem trata a detecção de subjetividade e de polaridade como um processo de classificação binário que ocorre em dois estágios. Cada um desses processos é realizado por uma camada independente, resultando numa arquitetura de múltiplas camadas. Nesta abordagem, a primeira camada identifica a subjetividade dos *tweets*, categorizando-os em *tweets* objetivos, que expressam fatos, e *tweets* subjetivos, que expressam opiniões. Opiniões, diferentemente de fatos, expressam os sentimentos, pareceres ou pensamentos das pessoas a respeito de entidades, eventos e das propriedades destes [Liu 2010]. A segunda camada, por sua vez, avalia a orientação semântica dos *tweets* que foram classificados como subjetivos, atribuindo-lhes polaridades positivas ou negativas.

2.1. *Corpora* e Pré-processamento

Neste estudo, utilizamos dois *corpora* de textos em língua portuguesa, o 7x1-PT e o Computer-BR. Moraes *et al.* [Moraes et al. 2015] construíram o *corpus* 7x1-PT que contém 2.728 *tweets*, sobre política e o desempenho dos jogadores da seleção brasileira, postados durante a partida em que o Brasil perdeu de 7 a 1 para a Alemanha na Copa do Mundo FIFA Brasil 2014. Dois anotadores, ambos da área de Ciência da Computação, classificaram manualmente o *corpus*. O coeficiente Kappa, que mede a concordância entre os anotadores, foi moderado, atingiu 0,53. Durante a anotação foram consideradas

quatro classes: ironia, negativo, neutro e positivo. Foram anotados como positivos os *tweets* que apresentavam elogios; como negativos aqueles que continham críticas; neutros aqueles que não continham opiniões (propagandas, por exemplo) ou tinham tanto um comentário positivo quanto um comentário negativo; e, como ironia aqueles cujo texto expressava uma polaridade oposta à interpretação semântica dada. Nós construímos o *corpus* Computer-BR, que possui 2.317 *tweets*, os quais extraímos do Twitter durante o ano de 2015. Coletamos os dados usando palavras-chave relacionadas a computadores, tais como *notebook*, *análise*, *teste*, e assim por diante. Quatro anotadores humanos, três da área da Ciência da Computação e um da área da Linguística, definiram manualmente a polaridade dos *tweets*. Três anotadores participaram de todo o processo de anotação e, nos casos de desacordo entre eles, o quarto anotador decidiu a polaridade final. Nós consideramos as mesmas quatro classes que o *corpus* 7x1-PT e revisamos a anotação até alcançarmos um nível de concordância significativo. O coeficiente Kappa foi de 0,69, considerado como substancial.

Como nós não tratamos ironia neste trabalho, optamos por categorizar os *tweets* desta classe como negativos. Tomamos essa decisão, pois estes *tweets* expressavam, em sua maioria, sentimentos negativos (por exemplo: "Aiii que maravilha, meu notebook parou de ligar!"). Nós planejamos investigar a ironia em trabalhos futuros. A Tabela 1 mostra a distribuição da polaridade nesses *corpora*. Em textos da *Web*, com os quais trabalhamos, o pré-processamento é uma etapa fundamental para o sucesso da aplicação. Vários fatores reduzem a eficiência dos classificadores automáticos de textos publicados em *microblogs*, tais como: erros ortográficos, problemas de pontuação, *emoticons*, linguagem coloquial, o uso não convencional de letras maiúsculas e minúsculas, abreviações, siglas, gírias, partes de texto não informativas para a tarefa (*HTML tags*, *scripts* e anúncios), dentre outros. Além disso, muitos termos do domínio tecnológico são usados em inglês, isto é, não são traduzidos para o português. Para reduzir esse problema, é preciso normalizar os *tweets*. Assim, na fase de pré-processamento de texto, nós removemos (ou tratamos) caracteres especiais, transformamos *emoticons* e *hyperlinks* em palavras, corrigimos o uso não convencional de letras maiúsculas e substituímos as abreviações e gírias por expressões habituais, por exemplo, "vc" em "você" e "novis" em "novidades". Após a fase de normalização, nós lematizamos e anotamos o texto dos *tweets* utilizando *part-of-speech* (PoS) *tags*. Para esta tarefa, nós testamos duas ferramentas de anotação linguística, o *parser* Visual Interactive Syntax Learning⁴ (VISL) e o Tree-Tagger⁵. Nas seções seguintes, nós detalhamos os classificadores que usamos em nossa abordagem.

Tabela 1. Distribuição das classes de sentimentos nos *corpora*.

Polarity	7x1-PT (%)	Computer-BR (%)
Negative	1,178 (43.18 %)	443 (19.1 %)
Neutral	1,101 (40.36 %)	1,677 (72.4 %)
Positive	449 (16.46 %)	197 (8.5 %)

Nós testamos e comparamos dois métodos de classificação de *tweets*: baseado em léxico e baseado em aprendizado de máquina. O primeiro método classifica os *tweets*

⁴A ferramenta VISL provê rotulagem *online* (<http://beta.visl.sdu.dk/visl/pt/>) e usa o *parser* PALAVRAS, desenvolvido por Bick [Bick 2000].

⁵<http://www.cis.uni-muenchen.de/~schmid/tools/TreeTagger/>

a partir da polaridade das palavras existentes nesses tweets. Essa polaridade é definida por dicionários de sentimentos. O segundo método, por sua vez, utiliza as palavras dos *tweets* e suas polaridades para definir o vetor de características⁶ e o algoritmo *Sequential Optimization Minimal* como técnica de classificação.

2.2. Método baseado em Léxico

No método baseado em léxico, usamos os dicionários Sentilex-PT [Carvalho and Silva 2015] e WordNetAffectBR [Pasqualotti and Vieira 2008] para determinar a subjetividade e a polaridade dos *tweets*. Escolhemos esses léxicos por estarem disponíveis e por terem sido utilizados em outros trabalhos [Souza and Vieira 2012]. Utilizamos os dois léxicos conjuntamente em função da melhora nos resultados. Primeiro, pesquisamos a polaridade dos termos⁷ no SentiLex-PT. Caso o termo não seja localizado, o procuramos no WordNetAffectBR. Optamos por esta ordem de busca, pois o SentiLex-PT é maior e oferece uma anotação mais precisa, uma vez que define a polaridade considerando a função sintática do termo (sujeito ou objeto). Testamos o método nas duas camadas da nossa arquitetura. Na camada de subjetividade, o *tweet* é classificado como subjetivo quando pelo menos uma das suas palavras tem polaridade positiva ou negativa. Essa polaridade é identificada por adjetivos, verbos e substantivos (não usamos advérbios, pois, estatisticamente, eram menos expressivos nos *corpora* usados). Por exemplo, palavras como *rápido* (adjetivo), *amar* (verbo) e *alegria* (substantivo) expressam sentimentos com polaridade positiva, enquanto que palavras como *devagar* (adjetivo), *odiar* (verbo), e *tristeza* (substantivo) têm polaridades negativas. A polaridade é neutra quando a palavra não é nem positiva nem negativa; neste caso, o *tweet* é classificado como objetivo. Já na camada de polaridade, um *tweet* é classificado como positivo quando a soma das polaridades das palavras contidas nele resultam em um valor positivo; caso contrário, o *tweet* é classificado como negativo.

2.3. Método baseado em Aprendizado de Máquina

No método baseado em aprendizado de máquina, utilizamos o algoritmo de classificação *Optimization Minimal Sequential* (SMO) [Platt 1998] da ferramenta Weka⁸. O SMO é uma versão do *Support Vector Machine* (SVM). Ele foi escolhido por apresentar um bom desempenho como classificador binário, mesmo quando os dados de entrada são esparsos [Platt 1999], que é o caso do nosso trabalho. Além disso, a quantidade de memória necessária para a execução do SMO é linear em relação ao tamanho do conjunto de treino, o que o torna capaz de lidar com conjuntos de treino grandes. Em nosso estudo, escolhemos, aleatoriamente, 80% dos *tweets* de cada *corpus* para definir o conjunto de treino, e o restante para definir o conjunto de teste. Como a seleção de características é uma etapa crucial nesta abordagem, nós testamos um novo método nesta fase, a medida de relevância *Comprehensive Measurement Feature Selection* (CMFS) [Yang et al. 2012, Yang et al. 2014]. De acordo com Yang *et al.* [Yang et al. 2012], a relevância de uma palavra pode ser calculada multiplicando-se a probabilidade $P(w_k|c_j)$ da palavra w_k ocorrer na categoria c_j , pela probabilidade $P(c_j|w_k)$ da palavra w_k pertencer à categoria c_j , sempre que a palavra w_k ocorre. A Equação 1 ilustra como

⁶Vetor de características é um vetor numérico usado para estruturar os *tweets*. Cada posição desse vetor é relativa a uma palavra (*feature*).

⁷Nesse trabalho, os termos são as palavras existentes em um *tweet*.

⁸<http://www.cs.waikato.ac.nz/ml/weka/>

é calculada a medida CMFS. Nós escolhemos essa medida de relevância porque é nova, adequada para conjuntos desbalanceados e pelos bons resultados obtidos em [Yang et al. 2014, Moraes et al. 2016]. Neste último, a medida foi usada com o algoritmo SMO para classificar a subjetividade dos *tweets*. A medida CMFS foi comparada a medidas tradicionais como frequência absoluta e relativa e obteve resultados animadores.

$$CMFS(w_k, c_j) = \frac{P(w_k|c_j)P(c_j|w_k)}{P(w_k)} \quad (1)$$

Inicialmente, nós extraímos as palavras existentes nos *tweets* que pertenciam ao conjunto de treino, organizando-as conforme a classe do *tweet* e a camada da arquitetura. Para a camada de subjetividade, nós construímos duas listas de palavras: uma contendo as palavras dos *tweets* objetivos e outra com as palavras dos *tweets* subjetivos. Para a camada de polaridade, o processo foi semelhante, no entanto, usamos apenas os *tweets* subjetivos, organizando suas palavras em duas listas: uma com as pertencentes aos *tweets* positivos e outra com as pertencentes aos *tweets* negativos. Com base na relevância definida pelo CMFS, nós usamos a técnica de *ranking* para definir as n palavras mais relevantes de cada classe de *tweets* em cada camada (testamos os valores para n que variavam de 10 a 100). Para completar a geração da *bag-of-words* (*bow*), nós testamos ainda duas estratégias. Na primeira, a de união, reunimos as palavras mais relevantes de cada classe em uma única lista. Na segunda, fizemos o mesmo, porém excluimos as palavras comuns a ambas as classes. Nós também testamos duas formas de modelo de espaço vetorial para representar os *tweets*: binário e baseado em polaridade. Na representação binária, os valores são usados para indicar se o *tweet* contém (1) ou não contém (0) um termo da *bow*. Na representação baseada em polaridade, substituímos os valores binários pelas polaridades das palavras. Definimos a polaridade a partir dos léxicos descritos na Seção 2.2. Após o teste, obtivemos bons resultados usando a *bow* baseada na segunda estratégia (excluindo as palavras existentes em ambas as classes) e o modelo de espaço vetorial baseado em polaridade.

2.4. Camada de Classificação de Subjetividade

A camada de classificação de subjetividade define se uma sentença é objetiva ou subjetiva. Em nossa abordagem, consideramos *tweets* com polaridade positiva ou negativa como subjetivos, e os *tweets* com polaridade neutra como objetivos. Independentemente da abordagem de classificação e do *corpus* adotados, os textos foram pré-processados da mesma forma. Entretanto, aplicamos heurísticas específicas apenas ao classificador baseado em léxico. Em uma análise preliminar, percebemos que um número considerável de *tweets* objetivos foram classificados como subjetivos. Esse foi o caso dos *tweets* contendo propaganda, como "VENDO NOTEBOOK MARCA DELL Excelente condição!". Esse problema de classificação acontecia sempre que havia no *tweet* alguma palavra com polaridade sendo usada para promover o produto descrito no texto (no exemplo, a palavra "excelente"). Percebemos, também, outros erros de classificação, mas de menor incidência, decorrentes da ausência do tratamento da negação. Para evitar esses erros, criamos duas heurísticas para serem aplicadas antes do classificador. Nós elaboramos uma lista com as 36 palavras que mais apareciam em propagandas, tais como o *ofertas*, *vendo* e *liquidação*, e, com base nela, criamos uma heurística de propaganda que definia como objetivos aqueles *tweets* que tinham pelo menos uma palavra dessa lista. Embora o

número de *tweets* com negação nos *corpora* fosse baixo, nós criamos uma heurística de negação que revertia a polaridade das palavras localizadas a uma distância de 3 termos de palavras negativas, tais como *não* e *nunca*. Com a aplicação destas heurísticas, a acurácia melhorou cerca de 2%.

Tabela 2. Resultados da Classificação de Subjetividade para o *corpus* Computer-BR (anotação linguística feita com a ferramenta TreeTagger)

Método / Classe	Aprendizagem de Máquina			Léxico		
	Pr	Re	F1	Pr	Re	F1
Objetivo	0,81	0,92	0,86	0,73	0,95	0,83
Subjetivo	0,68	0,44	0,53	0,41	0,09	0,15

Para avaliar os resultados, adotamos as medidas habituais de recuperação de informação: *Precision (Pr)*, *Recall (Re)*, *F-measure (F1)* e Acurácia. Como os conjuntos de treino e teste são escolhidos aleatoriamente, realizamos 5 execuções e calculamos a média dos valores obtidos nessas execuções. Na camada de classificação de subjetividade, obtivemos melhores resultados usando a ferramenta de anotação TreeTagger. As Tabelas 2 e 3 mostram os resultados médios que obtivemos para as classes subjetiva e objetiva. Obtivemos uma média de 78,66% de Acurácia, para o *corpus* Computer-BR, e de 68,70% para o *corpus* 7x1-PT. Para ambos os *corpora*, obtivemos os melhores resultados de classificação com o algoritmo SMO. Para o *corpus* Computer-BR atingimos uma *F1 score* média de 0,75, e para o *corpus* 7x1-PT, de 0,67. No Computer-BR, o desbalanceamento das amostras do conjunto de treino era maior. O número de *tweets* objetivos era mais que o dobro do número de *tweets* subjetivos, sendo que cerca de 30% dos *tweets* objetivos eram propaganda. O volume maior de *tweets* objetivos foi uma das razões dos bons resultados obtidos para a classe dos *tweets* objetivos. Por outro lado, a classe de *tweets* subjetivos recebeu muitos "falsos positivos" (vários anúncios foram classificados como subjetivos), o que afetou negativamente os resultados. Já no caso do *corpus* 7x1-PT, o desbalanceamento era muito menor. O principal problema foi o vocabulário, uma vez que, no domínio de futebol, várias palavras e expressões não foram encontrados no léxico ou tinham diferentes polaridades em função do domínio. Por exemplo, a palavra *cartão*, na maioria dos domínios, tem polaridade neutra, mas, no domínio do futebol, *cartão* tem conotação negativa. Mais detalhes sobre essa etapa de classificação estão em [Moraes et al. 2016].

Tabela 3. Resultados da Classificação de Subjetividade para o *corpus* 7x1-PT (anotação linguística feita com a ferramenta TreeTagger)

Método / Classe	Aprendizagem de Máquina			Léxico		
	Pr	Re	F1	Pr	Re	F1
Objetivo	0,67	0,46	0,54	0,41	0,89	0,56
Subjetivo	0,69	0,80	0,78	0,62	0,12	0,21

2.5. Camada de Classificação de Polaridade

A camada de classificação de polaridade define se o *tweet* classificado previamente como subjetivo é positivo ou negativo. Para essa camada, o método baseado em aprendizado de máquina também foi melhor. Obtivemos uma acurácia média de 55,24% para o *corpus*

Computer-BR, e de 53,24% para o *corpus* 7x1-PT. As tabelas 4 e 5 mostram os valores médios que obtivemos para as classes negativa e positiva. Em todos os testes, nós usamos a ferramenta TreeTagger para a anotação, em razão dos bons resultados obtidos na camada anterior. Em ambos os *corpora*, o número de amostras positivas é pequeno e o número de *tweets* com ironia, especialmente no *corpus* 7x1-PT, é grande. A ironia foi uma das principais razões do baixo desempenho do classificador para o *corpus* 7x1-PT.

Tabela 4. Resultados da Classificação de Polaridade para o *corpus* Computer-BR

Método / Classe	Aprendizagem de Máquina			Léxico		
	Pr	Re	F1	Pr	Re	F1
Negativo	0,56	0,96	0,71	0,34	0,88	0,49
Positivo	0,41	0,39	0,39	0,18	0,40	0,24

Tabela 5. Resultados da Classificação de Polaridade para o *corpus* 7x1

Método / Classe	Aprendizagem de Máquina			Léxico		
	Pr	Re	F1	Pr	Re	F1
Negativo	0,54	0,95	0,69	0,46	0,66	0,54
Positivo	0,53	0,31	0,39	0,26	0,51	0,34

Na seção seguinte, comparamos os resultados da arquitetura de múltiplas camadas com os resultados da arquitetura de camada única, a fim de analisarmos a contribuição da nossa abordagem.

3. Comparação com a Arquitetura de Camada Única

Na arquitetura de camada única, nós classificamos os *tweets* como positivos, negativos ou neutros. Quando utilizamos o método baseado em léxico, as arquiteturas de camadas única e a de múltiplas camadas produziram os mesmos resultados. Uma vez que a classificação depende apenas da polaridade da palavra, a arquitetura de múltiplas camadas simplesmente divide o processo em duas fases. Entretanto, o método baseado em aprendizado de máquina apresentou ganhos significativos porque a camada que classifica polaridade é especializada. Neste caso, a classificação muda porque criamos uma nova *bag-of-words* específica para *tweets* positivos e negativos. Além disso, como a classificação é binária as chances do algoritmo SMO obter melhores resultados aumentam.

Tabela 6. Medida da Acurácia Global

Corpus	Ferramenta	Camada Única	Múltiplas Camadas
Computer-BR	VISL	75,26%	75,56%
Computer-BR	TreeTagger	76,25%	76,37%
7x1-PT	VISL	54,97%	55,30%
7x1-PT	TreeTagger	59,96%	57,03%

Nas seções anteriores ao apresentarmos os resultados da abordagem multicamadas, nós calculamos a acurácia dos resultados para cada camada. No entanto, para que possamos comparar os resultados das duas arquiteturas para a abordagem de aprendizagem de máquina (que obteve melhores resultados), precisamos recalculamos os resultados

da multicamadas de uma forma mais geral (abrangendo todas das camadas) para que possamos perceber os ganhos e as perdas da arquitetura. Olhar apenas para os resultados da camada de polaridade é insuficiente para perceber a efetividade da abordagem, a polaridade depende do desempenho da camada de subjetividade. Se esta camada tiver uma boa precisão na classe dos subjetivos e uma precisão ruim nos objetivos, os resultados da segunda camada serão muito bons, pois o filtro foi muito "restritivo". No entanto, isso não é de fato um ganho, pois a classificação incorreta dos subjetivos como objetivos não é diretamente percebida. Por outro lado, se a classe subjetiva tiver uma precisão mais baixa em razão de muitos falso-positivos (filtro mais flexível), os resultados da camada de polaridade irão cair, pois os objetivos que passarem para a camada seguinte serão classificados incorretamente. No entanto, isso não determina que a classificação foi de fato ruim, se, em valores absolutos, os acertos em polaridade (*tweets* positivos e negativos) forem maiores. A Tabela 6 mostra os valores desta medida para ambas as abordagens: camada única e múltiplas camadas. Sendo que para esta última os valores foram recalculados. A análise dos resultados (Tabela 6) mostra que o ganho utilizando a arquitetura de múltiplas camadas é pequeno, menor que 1% na maioria dos testes. No último teste, no qual aplicamos o anotador TreeTagger no *corpus* 7x1-PT, o desempenho foi ainda menor. Isso acontece devido à precisão dos *tweets* objetivos que diminui consideravelmente na arquitetura de múltiplas camadas. Contudo, o ganho se torna evidente quando calculamos a acurácia considerando apenas os *tweets* positivos e os negativos (Tabela 7).

Tabela 7. Medida da acurácia para as classes positiva e negativa.

Corpus	Ferramenta	Camada Única	Múltiplas Camadas
Computer-BR	VISL	28,91%	31,25%
Computer-BR	TreeTagger	29,69%	35,31%
7x1-PT	VISL	67,54%	97,46%
7x1-PT	TreeTagger	70,17%	89,49%

A arquitetura de múltiplas camadas classifica muito melhor estes *tweets*, no entanto o ganho depende do anotador linguístico empregado e do *corpus* usado. No caso do *corpus* Computer-BR, a abordagem de múltiplas camadas classifica melhor a polaridade dos *tweets*, de 2% (usando VISL) a 5% (usando TreeTagger). No caso de 7x1-PT *corpus*, o ganho é maior, variando de 19% (usando TreeTagger) a 29% (usando VISL). Os anotadores linguísticos TreeTagger e VISL usam heurísticas diferentes, as quais influenciam os estágios de tokenização, lematização e de atribuição de *tags* gramaticais às palavras. Observamos que em ambos os *corpora*, a ferramenta TreeTagger atribuiu mais *tags* verbais do que *tags* substantivais às palavras. A ferramenta VISL, por outro lado, atribuiu harmonicamente essas *tags* às palavras dos *corpora*. Por exemplo, a ferramenta VISL anotou a palavra "Dell" como o substantivo próprio (*tag* PROP), enquanto a ferramenta TreeTagger não reconheceu esta palavra, anotando-a como verbo (*tag* V). Tais diferenças na anotação influenciam os resultados, uma vez que o lema é usado para encontrar a polaridade das palavras tanto no método baseado em léxico, quanto no método baseado em aprendizado de máquina. Ambos os anotadores são amplamente conhecidos e utilizados para textos em língua portuguesa, uma vez que eles oferecem um bom desempenho (com precisão de pelo menos 0,9) em textos formais. Cabe mencionar que, no caso de textos informais, como *tweets*, o desempenho destes anotadores é inferior, visto que tais ferramentas foram construídas considerando a estrutura gramatical de textos formais. Assim,

prover boa anotação para textos da *Web* é também um dos desafios da área.

4. Trabalhos Relacionados

A maior parte da literatura sobre Análise de Sentimentos para a língua portuguesa aborda tarefas específicas, tais como a classificação de polaridade em nível de sentença e em nível de aspecto. Em aplicações em nível de sentença, nas quais as frases são classificadas como positivas, negativas ou neutras, a acurácia varia de 55% a 71,79% [Santos et al. 2015, Rosa et al. 2013, Morgado 2012, Souza and Vieira 2012]. Santos *et al.* [Santos et al. 2015] classificam manchetes jornalísticas nas seguintes categorias de sentimento: positivo, negativo ou neutro. A adição dos recursos sintáticos (relação argumento1-verbo-argumento2) aos experimentos produziram melhores resultados, fazendo com que a precisão variasse de 59% a 63,50%. Os autores utilizaram dois algoritmos de aprendizado de máquina para a classificação, SMO e Random Forest, e os *corpora* SemEval2007 (constituído de textos traduzidos para o Português) e FootballNewsPT. Rosa *et al.* [Rosa et al. 2013] também usaram o algoritmo SMO para a polarização de textos curtos. Na abordagem dos autores, os *tweets* neutros não foram considerados. Eles obtiveram uma acurácia de 71,79%, e F-measure de 0,87 para frases positivas, e de 0,91 para frases negativas. Nas abordagens baseadas em léxico, a acurácia para a língua portuguesa variou de 55% a 58% [Filho et al. 2013, Morgado 2012, Souza and Vieira 2012]. Poucas pesquisas em português são conduzidas empregando essas duas tarefas combinadas. Lambert e Rodriguez-Penagos [Lambert and Rodriguez-Penagos 2014] adotaram uma arquitetura de múltiplas camadas em nível de entidade, na qual a primeira camada identificava a subjetividade, e a segunda camada determinava a polaridade. Ao aplicar essa abordagem, os autores utilizaram um conjunto de ferramentas linguísticas para extrair informações morfossintáticas do texto e, em seguida, determinar a polaridade das palavras usando o dicionário SentiLex. Eles adotaram dois *corpora* para esse estudo, Bosque 8.0 [Afonso et al. 2002] e Mac Morpho [Aluísio et al. 2003]. Na primeira camada, obteram uma F1 *score* de 0,39, enquanto que, na segunda camada, a F1 *score* foi superior a 0,65. Nós ressaltamos que os recursos linguísticos para a Análise de Sentimentos em português ainda são limitados. Tal escassez de *benchmark corpora*, por exemplo, faz com que a comparação de resultados seja mais desafiadora.

5. Conclusões e Trabalhos Futuros

Neste trabalho, desenvolvemos uma arquitetura de múltiplas camadas para classificar a polaridade de *tweets* em português em nível de sentença. A análise do nosso estudo produz dois resultados importantes. Primeiro, nós demonstramos que esta abordagem obtém melhores resultados do que a arquitetura com uma única camada, especialmente quando usamos o método de classificação baseado em aprendizado de máquina. Segundo, verificamos que a escolha dos anotadores linguísticos influencia consideravelmente a qualidade da tarefa de classificação. A medida CMFS, indicada para desbalanceamento de classes, teve desempenho aquém do esperado. Consideramos, ainda, difícil a comparação dos resultados com os outros trabalhos por diferentes razões, tais como: indisponibilidade de *corpora*, pouca informação sobre o método de anotação e sobre o pré-processamento dos *corpora*, quando encontrados. Em trabalhos futuros, nós pretendemos melhorar a normalização de textos em língua portuguesa, a fim de aumentar o desempenho dos anotadores e, também, expandir a classificação para o nível de entidade, considerando ironia.

6. Agradecimentos

Este projeto tem o apoio financeiro da empresa Dell e da PUCRS (EDITAL N. 01/2015 Chamada para o Programa de Apoio à Atuação de professores Horistas em Atividades de Pesquisa na PUCRS).

Referências

- Afonso, S., Bick, E., Haber, R., and Santos, D. (2002). Floresta sintá (c) tica: a treebank for portuguese. In *In Proceedings of the 3rd Intern. Conf. on Language Resources and Evaluation (LREC)*.
- Aluísio, S., Pelizzoni, J., Marchi, A. R., de Oliveira, L., Manenti, R., and Marquiasfável, V. (2003). An account of the challenge of tagging a reference corpus for brazilian portuguese. In *Computational Processing of the Portuguese Language*, pages 110–117. Springer.
- Banks, A. (2015). Brasil digital future in focus 2015. <http://blog.aotopo.com.br/wp-content/uploads/2015/02/Futuro-Digital-do-Brasil-em-Foco-2015-ComScore.pdf>. On-line; accessed 13 July 2016.
- Bick, E. (2000). *The Parsing System PALAVRAS: Automatic Grammatical Analysis of Portuguese in a Constraint Grammar Framework*. Aarhus University Pres, Aarhus.
- Cambria, E., Schuller, B., Xia, Y., and Havasi, C. (2013). New avenues in opinion mining and sentiment analysis. *IEEE Intelligent Systems*, 28(2):15–21.
- Carvalho, P. and Silva, M. J. (2015). Sentilex-PT: Principais características e potencialidades. In *Linguística, Informática e Tradução: Mundos que se Cruzam*.
- de Paiva, V., Rademaker, A., and de Melo, G. (2012). Openwordnet-pt: An open Brazilian Wordnet for reasoning. In *Proceedings of COLING 2012: Demonstration Papers*, pages 353–360, Mumbai, India. The COLING 2012 Organizing Committee.
- Fersini, E., Messina, E., and Pozzi, F. A. (2014). Subjectivity, polarity and irony detection: A multi-layer approach. In *First Italian Conference on Computational Linguistics CLiC-it 2014. the Fourth International Workshop EVALITA*.
- Filho, P. P. B., Pardo, T. A. S., and Alusio, R. M. (2013). An evaluation of the brazilian portuguese liwc dictionary for sentiment analysis. In *9th Brazilian Symposium in Information and Human Language Technology*, Fortaleza, Ceara.
- Généreux, M. and Martinez, W. (2012). Contrasting objective and subjective portuguese texts from heterogeneous sources. In *Proceedings of the Workshop on Innovative Hybrid Approaches to the Processing of Textual Data, HYBRID '12*, pages 46–51, Stroudsburg, PA, USA. Association for Computational Linguistics.
- Kamal, A. (2013). Subjectivity classification using machine learning techniques for mining feature-opinion pairs from web opinion sources. *CoRR*, abs/1312.6962.
- Kiritchenko, S., Zhu, X., and Mohammad, S. M. (2014). Sentiment analysis of short informal texts. *J. Artif. Int. Res.*, 50(1):723–762.
- Lambert, P. and Rodriguez-Penagos, C. (2014). Adapting freely available resources to build an opinion mining pipeline in portuguese. In *Proceedings of the Ninth Inter-*

- national Conference on Language Resources and Evaluation (LREC'14)*, Reykjavik, Iceland. European Language Resources Association (ELRA).
- Liu, B. (2010). Sentiment analysis and subjectivity. *Handbook of Natural Language Processing*, 2nd ed.
- Moraes, S., Manssour, I., and Silveira, M. S. (2015). 7x1-pt: um corpus extraído do twitter para análise de sentimentos em língua portuguesa. In *X Brazilian Symposium in Information and Human Language Technology (STIL)*, *4th Brazilian Conference on Intelligent Systems (BRACIS)*, Natal, RN, Brazil.
- Moraes, S. M. W., Santos, A. L. L., Redecker, M., Machado, R. M., and Meneguzzi, F. R. (2016). *Comparing Approaches to Subjectivity Classification: A Portuguese Tweets*, pages 86–94. Springer International Publishing, Cham.
- Morgado, I. C. (2012). Classification of sentiment polarity of portuguese on-line news. In *Proceedings of the 7th Doctoral Symposium in Informatics Engineering*, pages 139–150.
- Pasqualotti, P. and Vieira, R. (2008). Wordnet affect br: uma base lexical de emoções para a língua portuguesa. *RENOTE. Revista Novas Tecnologias na Educação*, 6:1–10.
- Platt, J. (1998). Fast training of support vector machines using sequential minimal optimization. In Schölkopf, B., Burges, C., and Smola, A., editors, *Advances in Kernel Methods – Support Vector Learning*, pages 42–65. MIT Press, Cambridge, MA.
- Platt, J. C. (1999). Advances in kernel methods. chapter Fast Training of Support Vector Machines Using Sequential Minimal Optimization, pages 185–208. MIT Press, Cambridge, MA, USA.
- Prata, D. N., Soares, K. P., Silva, M. A., Trevisan, D. Q., and Letouze, P. (2016). Social data analysis of brazilians mood from twitter. *International Journal of Social Science and Humanity*, 6(3):179–183.
- Rosa, R. L., Rodriguez, D. Z., and Bressan, G. (2013). Sentimeter-br: A social web analysis tool to discover consumers' sentiment. In *MDM (2)*, pages 122–124. IEEE Computer Society. 978-1-4673-6068-5.
- Santos, A. P., Ramos, C., and Marques, N. C. (2015). Sentiment classification of portuguese news headlines. *International Journal of Software Engineering and Its Applications*, 9(9):9–18.
- Silva, B. C. D. d. (2010). Brazilian portuguese wordnet: a computational linguistic exercise of encoding bilingual relational lexicons. *International Journal of Computational Linguistics and Applications*, 1(1):137–150.
- Souza, M. and Vieira, R. (2012). Sentiment analysis on twitter data for portuguese language. In *Proceedings of the 10th International Conference on Computational Processing of the Portuguese Language, PROPOR'12*, pages 241–247, Berlin, Heidelberg. Springer-Verlag.
- Yang, J., Liu, Y., Zhu, X., Liu, Z., and Zhang, X. (2012). A new feature selection based on comprehensive measurement both in inter-category and intra-category for text categorization. *Information Processing & Management*, 48(4):741 – 754.
- Yang, J., Qu, Z., and Liu, Z. (2014). Improved feature-selection method considering the imbalance problem in text categorization. *The Scientific World Journal*, page 7.